Sqoop

NOTA: por favor antes de continuar revisar la dirección IP y el puerto de Postgres, lo pueden hacer con el siguiente comando:

Docker inspect edvai_postgres

Para comenzar a utilizar sgoop debemos ingresar a la consola de Hadoop

Docker exec -it edvai_postgres bash

Verificar que estemos logueados con el usr hadoop y ya podemos comenzar a probar los siguientes comandos:

```
hadoop@0485e86b7577:/$ sqoop-version
warning: /usr/lib/sqoop/../nbase does not exist! HBase imports will fail.
Please set $HBASE_HOME to the root of your HBase installation.
Warning: /usr/lib/sqoop/../hcatalog does not exist! HCatalog jobs will fail.
Please set $HCAT_HOME to the root of your HCatalog installation.
Warning: /usr/lib/sqoop/../accumulo does not exist! Accumulo imports will fail.
Please set $ACCUMULO_HOME to the root of your Accumulo installation.
Warning: /usr/lib/sqoop/../zookeeper does not exist! Accumulo imports will fail.
Please set $ZOOKEEPER_HOME to the root of your Zookeeper installation.
2023-03-27 21:14:00,630 INFO sqoop.Sqoop: Running Sqoop version: 1.4.7
Sqoop 1.4.7
git commit id 2328971411f57f0cb683dfb79d19d4d19d185dd8
Compiled by maugli on Thu Dec 21 15:59:58 STD 2017
hadoop@0485e86b7577:/$
```

Verificar funcionamiento y versión:

Sqoop-version

Listar databases:

sqoop list-databases \

```
-connect jdbc:postgresql://172.17.0.3:5432/northwind \
-username postgres -P
Listar tablas:
sqoop list-tables \
-connect jdbc:postgresql://172.17.0.3:5432/northwind \
-username postgres -P
Ejecutar Queries:
sqoop eval \
-connect jdbc:postgresql://172.17.0.3:5432/northwind \
-username postgres \
-P \
-query "select * from region limit 10"
Importar tablas:
sqoop import \
 -connect jdbc:postgresql://172.17.0.3:5432/northwind \
 -username postgres\
 -table region\
 -m1\
 −P \
 -target-dir /sqoop/ingest \
 -as-parquetfile \
 -delete-target-dir
Importar tablas con filtro:
```

```
sqoop import \
 -connect jdbc:postgresql://172.17.0.3:5432/northwind \
 -username postgres\
 -table region\
 -m1\
 -P \
 -target-dir/sqoop/ingest/southern \
 -as-parquetfile \
 -where "region_description = 'Southern'" \
 -delete-target-dir
Importar tablas desde una query:
sqoop import \
 -connect jdbc:postgresql://172.17.0.3:5432/northwind \
 -username postgres\
 -query "select * from region where region_id = 3 AND \$CONDITIONS"\
 -m1\
 −P \
 -target-dir /sqoop/ingest \
 -as-parquetfile \
 -delete-target-dir
Una vez que hayamos hecho el import nos quedará un archivo parquet en la
siguiente ruta: /sqoop/ingest
Por lo que luego ya podemos ingresar a spark para comenzar a crear un dataframe
en base a esa data.
Creamos un dataframe leyendo el parquet que acabamos de importar con sgoop
df = spark.read.parquet("/sqoop/ingest/*.parquet")
Luego podemos revisar el esquema
df.printSchema()
Podemos revisar si se encuentra datos dentro del dataframe:
>>> df.show(5)
|order_id|customer_id|ship_country|unit_price|quantity|
```

++					
	10248	VINET	France	14.0	12
	10248	VINET	France	9.8	10
	10248	VINET	France	34.8	5
	10249	TOMSP	Germany	18.6	9
	10249	TOMSP	Germany	42.4	40
++					
		_			

only showing top 5 rows

APACHE nifi

Para comenzar debemos ingresar a la consola nifi o ejecutar desde la ventana de terminal de la vm el siguiente comando:

Docker exec -it nifi bash

Una vez que ingresamos ir a la carpeta /home/nifi

Y creamos 3 carpetas:

- Ingest
- Bucket
- hadoop

```
nifi@22b0603921b4:~$ mkdir ingest
```

Ingresamos a la carpeta ingest y bajamos el siguiente archivo con el siguiente comando:

wget https://data-engineer-edvai.s3.amazonaws.com/yellow tripdata 2021-01.csv

```
nie Edit View Search Terminal Help
nifi@22b060392lb4:~$ cd ingest/
nifi@22b060392lb4:~/ingest$ wget https://data-engineer-edvai.s3.amazonaws.com/yellow_tripdata_2021-01.csv
```

Luego vamos a la carpeta hadoop y creamos los siguientes archivos:

- core-site.xml
- hdfs-site.xml

De la siguiente manera (verificar si la dirección IP es la correcta):

```
Cat > core-site.xml
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<!--
Licensed under the Apache License, Version 2.0 (the "License");
you may not use this file except in compliance with the License.
You may obtain a copy of the License at
```

```
Unless required by applicable law or agreed to in writing, software
 distributed under the License is distributed on an "AS IS" BASIS,
 WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
 See the License for the specific language governing permissions and
 limitations under the License. See accompanying LICENSE file.
-->
<!-- Put site-specific property overrides in this file. -->
<configuration>
    property>
         <name>fs.defaultFS</name>
         <value>hdfs://172.17.0.2:9000
    </property>
</configuration>
Y luego Ctrl + D para finalizar la creación del archivo
Cat > hdfs-site.xml
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
 Licensed under the Apache License, Version 2.0 (the "License");
 you may not use this file except in compliance with the License.
 You may obtain a copy of the License at
  http://www.apache.org/licenses/LICENSE-2.0
 Unless required by applicable law or agreed to in writing, software
 distributed under the License is distributed on an "AS IS" BASIS,
 WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
 See the License for the specific language governing permissions and
 limitations under the License. See accompanying LICENSE file.
-->
<!-- Put site-specific property overrides in this file. -->
<configuration>
```

Luego ingresamos a la UI de nifi desde chrome e ingresamos la siguiente dirección:

https://localhost:8443/nifi/

Para averiguar el usr y pass realizamos los siguientes pasos:

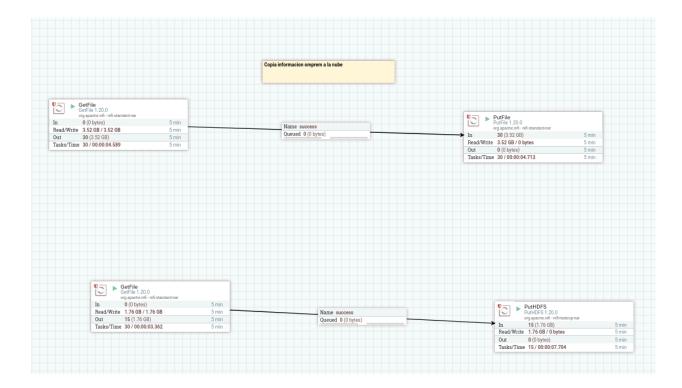
Linux/Mac
docker logs nifi | grep Generated
windows
docker logs nifi | findstr Generated

Deberíamos encontrar algo similar a esto:

Generated Username [55dc0025-37f0-48a2-9f21-7a9206105f0f] Generated Password [9EPoIAhJazbZ/EuCmNJqHwW7mlk4mQtS]

Una vez que ingresamos vamos a generar 4 procesadores:

- 2 GetFile
- 1 Putfile
- 1 PutHDFS



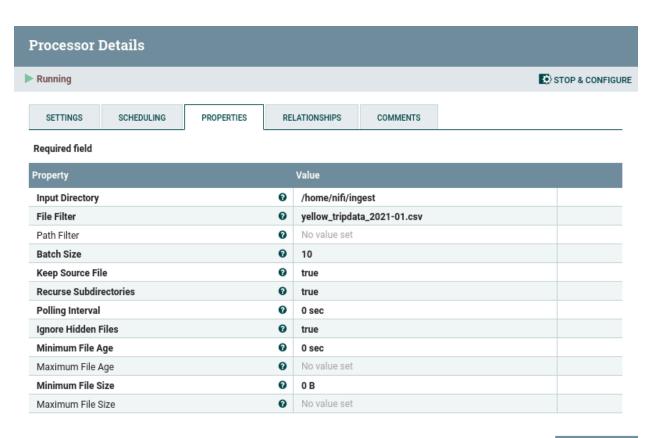
El primer proceso va a tomar datos desde /ingest y lo va a copiar a /bucket de la siguiente manera:

GETFILE

input directory: /home/nifi/ingest

File filter: yellow_tripdata_2021-01.csv (o dejar por default que no pone ningún filtro)

Scheduling: 10 seg



ок

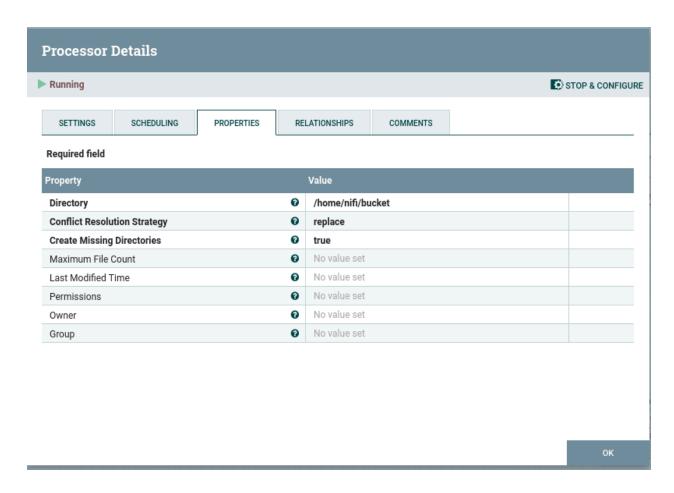
PutFile

Directory: home/nifi/bucket

Relationships:

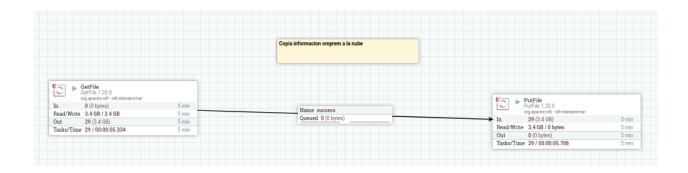
• Failure: retry and terminate

• Success: terminate



Lo linkeamos con el put file a través de la flecha

Luego ya lo podemos hacer correr, para verificar que funcionó OK debemos revisar la carpeta /home/nifi/bucket y ver si se encuentra el archivo yellow_tripdata_2021-01.csv



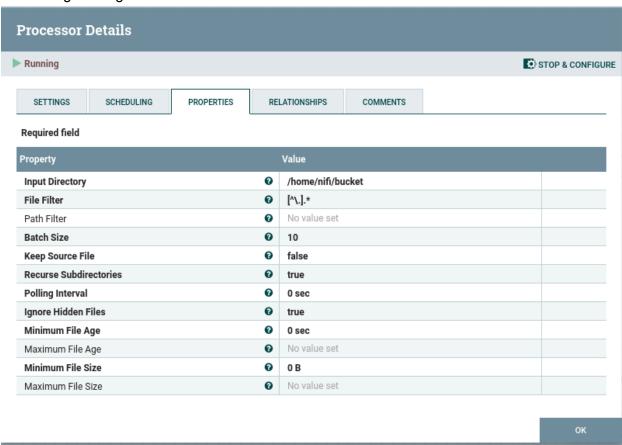
Ahora nos queda copiar el archivo /home/nifi/bucket/yellow_tripdata_2021-01.csv a la carpeta /nifi de HDFS

Getfile

Input directory: /home/nifi/bucket

File filter: dejarlo por default para que no filtre ningún archivo

Scheduling: 10 seg



PutHDFS

Luego creamos el procesador PutHDFS de la siguiente manera:

Hadoop configuration resources (archivos de configuración de hadoop): /home/nifi/hadoop/core-site.xml, /home/nifi/hadoop/hdfs-site.xml

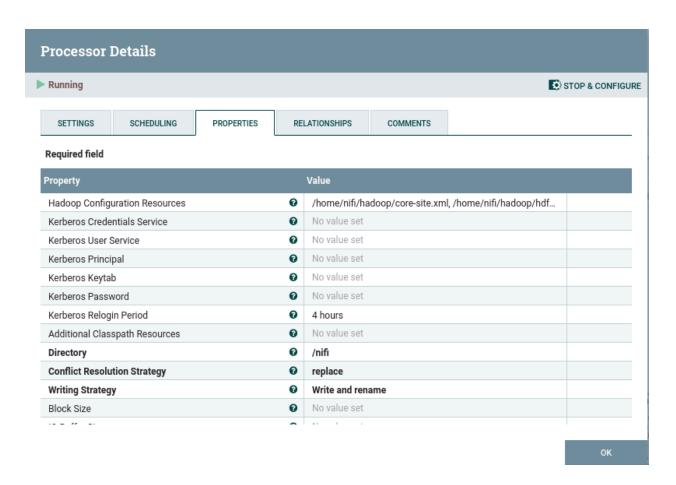
Directory: /nifi

Conflict resolution strategy: replace

Relationships:

• Failure: retry and terminate

• Success: terminate



Luego tenemos que revisar que nifi pueda escribir en el directorio /nifi Para esto ingresamos en la consola hadoop

Y escribimos en la consola hdfs dfs -ls /

Ahí revisamos que otros usuarios no pueden escribir en esa carpeta, por lo que vamos a modificar los permisos

```
hadoop@0485e86b7577:/$ hdfs dfs -ls /
Found 7 items
drwxr-xr-x - hadoop supergroup
                                         0 2023-03-21 09:02 /ingest
                                         0 2022-04-26 19:51 /inputs
drwxr-xr-x - hadoop supergroup
drwxr-xr-x - hadoop supergroup
                                         0 2022-01-22 21:35 /logs
drwxr-xr-x - hadoop supergroup
                                         0 2023-03-27 20:47 /nifi
                                         0 2023-03-27 19:47 /sqoop
drwxr-xr-x - hadoop supergroup
                                         0 2022-05-02 20:46 /tmp
drwxrwxr-x
             - hadoop supergroup
                                         0 2022-01-23 13:15 /user
drwxr-xr-x

    hadoop supergroup
```

Modificamos los permisos con el siguiente comando:

Hdfs dfs -chmod 777 /nifi

Luego verificamos que afectivamente el directorio /nifi tengan permisos para escribir otros usuarios

```
hadoop@0485e86b7577:/s hdfs dfs -chmod 777 /nifi
hadoop@0485e86b7577:/$ hdfs dfs -ls /
Found 7 items
            - hadoop supergroup
drwxr-xr-x
                                          0 2023-03-21 09:02 /ingest
                                         0 2022-04-26 19:51 /inputs
             - hadoop supergroup
drwxr-xr-x
                                         0 2022-01-22 21:35 /logs
drwxr-xr-x - hadoop supergroup
                                         0 2023-03-27 20:47 /nifi
drwxrwxrwx - hadoop supergroup
             - hadoop supergroup
                                          0 2023-03-27 19:47 /sqoop
drwxr-xr-x
                                         0 2022-05-02 20:46 /tmp
drwxrwxr-x

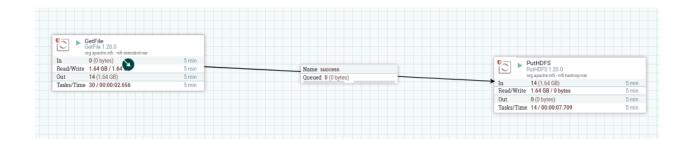
    hadoop supergroup

drwxr-xr-x

    hadoop supergroup

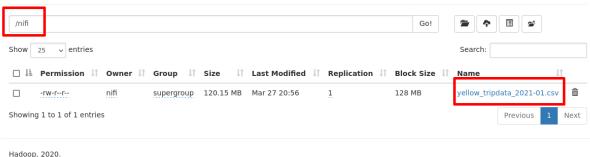
                                          0 2022-01-23 13:15 /user
```

Ahora si podemos darle start a la segunda parte del proces que me va a permitir copiar el archivo yellow_tripdata_2021-01.csv desde la carpeta /nifi/bucket al directorio /nifi



Para verificar que efectivamente copio el archivo lo podemos hacer desde la UI hadoop

Browse Directory



O desde la consola hadoop con el siguiente comando:

```
hadoop@0485e86b7577:/$ hdfs dfs -ls /nifi
Found 1 items
-rw-r--r--
            1 nifi supergroup 125981363 2023-03-27 21:50 /nifi/yellow_tripdata_2021-01.csv
hadoop@0485e86b7577:/$
```

Por lo que luego ya podemos ingresar a spark para comenzar a crear un dataframe en base a esa data.

Creamos un dataframe leyendo el parquet que acabamos de importar con sqoop df = spark.read.option("header", "true").csv("/nifi/*.csv")

Luego podemos revisar el esquema

```
>>> df.printSchema()
root
```

- |— VendorID: string (nullable = true)
- |- tpep_pickup_datetime: string (nullable = true)
- |- tpep_dropoff_datetime: string (nullable = true)
- |- passenger_count: string (nullable = true)
- |- trip_distance: string (nullable = true)
- |- Ratecode|D: string (nullable = true)
- |- store_and_fwd_flag: string (nullable = true)
- |- PULocation|D: string (nullable = true)
- |- DOLocation|D: string (nullable = true)
- |- payment_type: string (nullable = true)
- |- fare_amount: string (nullable = true)

|- extra: string (nullable = true) |- mta_tax: string (nullable = true) |- tip_amount: string (nullable = true) |- tolls_amount: string (nullable = true) |- improvement_surcharge: string (nullable = true) |- total_amount: string (nullable = true) |- congestion_surcharge: string (nullable = true)

only showing top 3 rows

Podemos revisar si se encuentra datos dentro del dataframe:

