Clase 7

Consigna: Por cada ejercicio, escribir el código y agregar una captura de pantalla del resultado obtenido.

Diccionario de datos:

https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf

 En Hive, crear la siguiente tabla (externa) en la base de datos tripdata: a. airport_trips(tpep_pickup_datetetime, airport_fee, payment_type, tolls_amount, total_amount)

2. En Hive, mostrar el esquema de airport_trips

```
describe formatted airport trips;
# col_name
                       data_type
                                               comment
tpep_pickup_datetetime date
airport_fee
                       float
payment_type
                       string
tolls_amount
                       float
total_amount
                       float
# Detailed Table Information
Database:
                       tripdata
Owner:
                        hadoop
                       Wed May 22 18:55:28 ART 2024
CreateTime:
LastAccessTime:
                       UNKNOWN
Retention:
                        hdfs://172.17.0.2:9000/user/hive/warehouse/tripdata.db/airport_trips
Location:
```

3. Crear un archivo .bash que permita descargar los archivos mencionados abajo e ingestarlos en HDFS:

Yellow_tripdata_2021-01.parquet

(https://edvaibucket.blob.core.windows.net/data-engineer-edvai/yellow_tripdata_2021-01 _parquet\?sp\=r\&st\=2023-11-06T12:52:39Z\&se\=2025-11-06T20:52:39Z\&sv\=2022-11-02\&sr\=c\&sig\=J4Ddi2c7Ep23OhQLPisbYaerlH472iigPwc1%2FkG80EM%3D)

Yellow_tripdata_2021-02.parquet(https://edvaibucket.blob.core.windows.net/data-engine er-edvai/yellow tripdata 2021-02.csv\?sp\=r\&st\=2023-11-06T12:52:39Z\&se\=2025-11-06T20:52:39Z\&sv\=2022-11-02\&sr\=c\&sig\=J4Ddi2c7Ep23OhQLPisbYaerlH472iigPwc 1%2FkG80EM%3D)

4. Crear un archivo .py que permita, mediante Spark, crear un data frame uniendo los viajes del mes 01 y mes 02 del año 2021 y luego Insertar en la tabla airport_trips los viajes que tuvieron como inicio o destino aeropuertos, que hayan pagado con dinero.

```
cat > spark_clase7.py
chmod 777 spark_clase7.py
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
from pyspark.sql import HiveContext
# Configuramos...
sc = SparkContext('local')
 spark = SparkSession(sc)
# Traemos las tablas
"fraction and the control of the con
 df2 = spark.read.option("header",

"true").parquet("hdfs://172.17.0.2:9000/ingest/yellow_tripdata_2021-02.parquet")
# Unimos las tablas
dfunion = df.union(df2)
# Creamos la vista para trabajar con sql
dfunion.createOrReplaceTempView("v_air")
# Selecciono las tablas que necesito, agrego el where y las casteo
     considero no hace falta usar dos o mas pasos para esta transformacion
 df_transform = spark.sql("""
                      SELECT
                                CAST(tpep_pickup_datetime AS DATE),
CAST(airport_fee AS FLOAT),
                                CAST (payment_type AS INT),
                                 CAST(tolls amount AS FLOAT),
                                CAST(total amount AS FLOAT)
                      {\tt FROM}\ {\tt v}\ {\tt air}
                      WHERE airport_fee IS NOT NULL AND payment_type = 2
 df transform.write.insertInto("tripdata.airport trips")
 #df transform.createOrReplaceTempView("a trips")
 #spark.sql("insert into tripdata.airport trips SELECT * from a trips")
     el insert me es mas facil con python ...
```

 Realizar un proceso automático en Airflow que orqueste los archivos creados en los puntos 3 y 4. Correrlo y mostrar una captura de pantalla (del DAG y del resultado en la base de datos)

```
chmod 777 airflow_clase7.py
from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days_ago
args = {
with DAG(
    dag_id='clase7',
    default_args=args,
schedule_interval='0 0 * * *',
    start_date=days_ago(2),
    dagrun_timeout=timedelta(minutes=60),
    tags=['ingest_clase7', 'transform_clase7'],
params={"example_key": "example_value"},
  as dag:
    comienza_proceso = DummyOperator(
   task_id='comienza_proceso',
    finaliza proceso = DummyOperator(
        task_id='finaliza_proceso',
    ingest = BashOperator(
         task_id='ingest',
        bash_command='/usr/bin/sh /home/hadoop/scripts/ingest_clase7.sh ',
    transform = BashOperator(
        task_id='transform',
        bash_command='ssh hadoop@172.17.0.2 /home/hadoop/spark/bin/spark-submit --files
         /home/hadoop/hive/conf/hive-site.xml /home/hadoop/scripts/spark_clase7.py',
    comienza proceso >> ingest >> transform >> finaliza proceso
   __name__ == "__main__":
dag.cli()
```

